

SCAD

Kazeto Fukasawa

平成 27 年 9 月 14 日

第 I 部 準備

1 フィッシャー情報量

$$I = E \left[\left(\frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 | \theta \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) | \theta \right] \quad (1)$$

定理 1

X_1, \dots, X_n が互いに独立に母数 θ をふくむ密度関数 $f(x, \theta)$ を持つ分布に従うとする。このとき、分布の背即例に関する適当な条件のもとで、 θ の任意の不偏推定量 $\hat{\theta}$ について

$$V(\hat{\theta}) \geq \frac{1}{nI} \quad (2)$$

が成り立つ。これをクラメール・ラオ不等式という。

ちなみに、正規分布の場合 $I = 1/\sigma^2$ になる。

2 正規直交行列

X_i に正規直交行列 (orthonotmal) を仮定すると、 β の推定値は $\mathbf{z} = X^T \mathbf{y}$ になる。 X を正規直交行列とすると、 $X^T X = E$ となるので。

第II部

SCAD

3 SCAD 推定値

$$p_{\lambda}^{SCAD}(\beta_j) = \begin{cases} \lambda|\beta_j| & \text{if } |\beta_j| \leq \lambda, \\ -\left(\frac{|\beta_j|^2 - 2a\lambda|\beta_j| + \lambda^2}{2(a-1)}\right) & \text{if } \lambda < |\beta_j| \leq a\lambda, \\ \frac{(a+1)\lambda^2}{2} & \text{if } |\beta_j| > a\lambda \end{cases} \quad (3)$$

この一回微分は、 $a > 2, \beta > 0$ のもとで

$$p'_{\lambda}(\beta) = \lambda\{I(\beta \leq \lambda) + \frac{(a\lambda - \beta)_+}{(a-1)\lambda}I(\beta > \lambda)\} \quad (4)$$

となり、 β の推定値は

$$\hat{\beta}_j^{SCAD} = \begin{cases} (|\hat{\beta}_j| - \lambda)_+ \text{sign}(\hat{\beta}_j) & \text{if } |\hat{\beta}_j| < 2\lambda, \\ \{(a-1)\hat{\beta}_j - \text{sign}(\hat{\beta}_j)a\lambda\}/(a-2) & \text{if } 2\lambda < |\hat{\beta}_j| \leq a\lambda, \\ \hat{\beta}_j & \text{if } |\hat{\beta}_j| > a\lambda \end{cases} \quad (5)$$

1 階微分と推定値

lasso($|\beta| > \lambda$ のケース)

3.0.1 連続であった方がよい理由

(5) を $\hat{\beta}$ を入力して $\hat{\beta}_j^{SCAD}$ を出力する関数 $f(\hat{\beta})$ とみると、hard thresholding では $\lim_{\hat{\beta} \rightarrow \lambda+} f(\hat{\beta}) = \hat{\beta}$, $\lim_{\hat{\beta} \rightarrow \lambda-} f(\hat{\beta}) = 0$ というように、同じ値への関数の極限值が左右で変わってしまう。つまり $\hat{\beta} = \lambda$ の点では、関数の値が定まらない。そうすると推定量として、 $\hat{\beta} = \lambda$ だった時にこまるので、連続の方が良い。

3.1 SCAD 推定値の仮定

仮定 1 観測データは独立である。

仮定 2 対数尤度関数を $l(\beta)$ とする。このとき、対数尤度関数の 1 階微分は以下を満たす。

$$E\left[\frac{\partial l(\beta)}{\partial \beta_j}\right] = 0, \quad j = 1, \dots, p$$

仮定 3 対数尤度関数 $l(\beta)$ の 2 階微分は以下を満たす。

$$E\left[-\frac{\partial^2 l(\beta)}{\partial \beta_j \partial \beta_k}\right] = E\left[\frac{\partial l(\beta)}{\partial \beta_j} \frac{\partial l(\beta)}{\partial \beta_k}\right], \quad j, k = 1, \dots, p$$

仮定 4 フィッシャー情報行列

$$I(\beta) = E\left[\frac{\partial l(\beta)}{\partial \beta} \frac{\partial l(\beta)}{\partial \beta'}\right]$$

は有限であり、真のパラメータ $\beta = \beta_0$ において $I(\beta_0)$ は正定値行列である。

仮定 5 パラメータ空間内 \mathbb{R}^p の部分集合 ω は真のパラメータ $\beta = \beta_0$ を含み、対数尤度関数の 3 階微分の絶対値

$$\left| \frac{\partial^3 l(\beta)}{\partial \beta_j \partial \beta_k \partial \beta_l} \right|$$

は全ての $\beta \in \omega$ について有限である。

仮定 6 正則化パラメータは以下の漸近的性質を持つ。

$$\lambda \rightarrow 0, \quad \sqrt{n}\lambda \rightarrow \infty$$

3.2 Oracle Procedure

A, A^* を以下のように定義する。

$$A = \{j; \beta_{0j} \neq 0\}, \quad A^* = \{j; \hat{\beta}_j \neq 0\} \quad (6)$$

つまり A は目的変数と真に関連する集合であり、 A^* は目的変数と関連すると推定された集合である。

Oracle procedure は以下の性質である。

$$\lim_{n \rightarrow \infty} P(A^* = A) = 1, \quad (7)$$

$$\sqrt{n}(\beta_{01} - \hat{\beta}_1) \rightarrow N(\mathbf{0}, \Sigma^*) \quad (8)$$

ここで、 β_{01} は目的変数と真に関連する説明変数の集合 A についての回帰係数ベクトル、 $\hat{\beta}_1$ は対応する推定された回帰係数ベクトルである。

つまり、(7) はスパース性、(8) は漸近正規性を表す。

上の仮定のもとで、SCAD 推定量は oracle procedure になる。

3.3 一致性

一致性を示すには、任意の $\epsilon > 0$ に対してある定数 C が存在し、確率 $1 - \epsilon$ 以上で $Q(\beta)$ を局所最大化する β が存在することを示せば、 $\|\hat{\beta} - \beta_0\| = O_p(\alpha_n)$ が成立する。

(? 局所最大化する β が存在 $\rightarrow \|\hat{\beta} - \beta_0\| = O_p(\alpha_n)$ が成立 がよくわからない。関数が連続であれば、 $f(\beta) - f(\beta_0) = 0$ になれば $\beta - \beta_0 = 0$ になっていく気がするが、これで示しているのは不等号であって等号ではない。任意の確率で成り立つからいいのか?)

(? 任意の確率で、それが 0 に近いことを言いたいのだとすると、extrem estimator と同じ話に見えるが、だとするとなぜ $1 - \epsilon$ の形になっている?)

$$P\left[\sup_{\|\mathbf{u}\|=C} Q(\beta_0 + \alpha_n \mathbf{u}) < Q(\beta_0)\right] \geq 1 - \epsilon, \quad (9)$$

$$\alpha_n = n^{-\frac{1}{2}} + d_n, \quad (10)$$

$$d_n = \max\{p'_{\lambda_n}(\beta_{0k}) ; \beta_{0k} \neq 0\}, \quad (11)$$

$Q(\beta)$ は SCAD 罰則付き対数尤度関数で、以下のように定義される。

$$Q(\beta) = L(\beta) - n \sum_{j=1}^p p(|\beta_j|) = \sum_{i=1}^n \log f(y_i | \mathbf{x}_i, \beta) - n \sum_{j=1}^p p_{\lambda_n}(|\beta_j|), \quad (12)$$

(? なぜ罰則項に n がある? あといつのまにか λ_n になってる。 n/n をかけていて、 n が外にあり、 $1/n$ が関数 p の中に入った?)

P の中に着目して、 $Q(\beta_0 + \alpha_n \mathbf{u}) - Q(\beta_0)$ が常に 0 以下となればよいので、

$$\begin{aligned} D_n(\mathbf{u}) &= Q(\beta_0 + \alpha_n \mathbf{u}) - Q(\beta_0) \\ &\leq L(\beta_0 + \alpha_n \mathbf{u}) - L(\beta_0) - n \sum_{j=1}^s \left[p_{\lambda_n}(|\beta_{j0} + \alpha_n u_j|) - p_{\lambda_n}(|\beta_{j0}|) \right] \end{aligned} \quad (13)$$

ここで、 s は β_{10} の数である。 $L(\beta_0 + \alpha_n \mathbf{u})$, $p_{\lambda_n}(|\beta_{j0} + \alpha_n u_j|)$ をそれぞれ β_0 の周りでテイラー展開して、

$$\begin{aligned} D_n(\mathbf{u}) &\leq \alpha_n L'(\beta_0)^T \mathbf{u} \\ &\quad - \frac{1}{2} \mathbf{u}^T I(\beta_0) \mathbf{u} \alpha_n^2 \{1 + o_p(1)\} \\ &\quad - \sum_{j=1}^s \left[n \alpha_n p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) u_j + n \alpha_n^2 p''_{\lambda_n}(|\beta_{j0}|) u_j^2 \{1 + o(1)\} \right] \end{aligned}$$

第 1 項目と第 2 項目は $O_p(n\alpha_n^2)$ であり、定数 C を十分大きく取ると第 1 項目と第 2 項目の和は負になり、第 3 項目は第 2 項目よりも小さくなるので、右辺は負になる。

(order については hancenP125)

(? $o_p(1)$ の部分はテイラー展開の 3 次の項だとは思うが、2 次の項でこうやってくれるのか？ 3 次の項を行列表記するとどうなる？ 行列表記できない気がする)

第 3 項目は、

$$\sqrt{s}n\alpha_n d_n \|\mathbf{u}\| + n\alpha_n^2 \max\{p''_{\lambda_n}(|\beta_{j0}|) : \beta_{j0} \neq 0\} \|\mathbf{u}\|^2 \quad (14)$$

で抑えられるため、第 2 項目が dominate する。

(? dominate っていまいちわからない。収束のオーダーの違いから、ある n_0 以上の n をとると、それだけ考えればいいということ？)

3 項目を詳しくみると、まず

$$\sum_{j=1}^s n\alpha_n p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) u_j \quad (15)$$

があり、 p'_{λ_n} の max をとると、 d_n になり、max をとっているのが常に正になり sign の部分もいらなくなる。

すると j に依存する部分が u_j だけになり、 $\sum_{j=1}^s u_j$ を $\|\mathbf{u}\|^2 = \sum_{j=1}^s u_j^2$ で置き換える。

そうすると $n\alpha_n d_n \|\mathbf{u}\|^2$ になるが、 \sqrt{s} はどこから出てきた？ あと $\|\mathbf{u}\|^2$ になっている。むりやり出すとしたら u_j を $\|\mathbf{u}\|^2$ で置き換えて、 $s\|\mathbf{u}\|^2$ になり、これのルートをとると $\sqrt{s}\|\mathbf{u}\|$ になって、 $\sqrt{s}n\alpha_n d_n \|\mathbf{u}\|$ に一致するが。

次に

$$n\alpha_n^2 p''_{\lambda_n}(|\beta_{j0}|) u_j^2 \{1 + o(1)\} \quad (16)$$

は、 $p''_{\lambda_n}(|\beta_{j0}|)$ の max をとって、 $o(1)$ 項を無視し、 $\sum_{j=1}^s u_j^2 = \|\mathbf{u}\|^2$ と表記を変えると一致する。

$\|\hat{\beta} - \beta_0\| = O_p(\alpha_n)$ については、

$$\hat{\beta} = \beta_0 + \alpha_n u \quad (17)$$

と定義すると、

$$\begin{aligned} \|\hat{\beta} - \beta_0\| &= \|\beta_0 + \alpha_n u - \beta_0\| \\ &= \|\alpha_n u\| = (\alpha_n u)^T (\alpha_n u) = \alpha_n^2 u^T u \end{aligned}$$

従ってこれを α_n で割ると、 $\alpha_n u^T u$ になる。 $\alpha_n = n^{-\frac{1}{2}} + d_n$ であり、 $n \rightarrow \infty$ で 0 になる。

3.4 スパース性

新たに以下を仮定する。

$$\liminf_{n \rightarrow \infty} \liminf_{\theta \rightarrow 0+} p'_{\lambda_n}(\theta)/\lambda_n > 0 \quad (18)$$

ある小さい $\epsilon_n = C/\sqrt{n}$ 、そして $j = s+1, \dots, d$ について、

$$\frac{\partial Q(\beta)}{\partial \beta_j} < 0 \quad \text{for } 0 < \beta_j < \epsilon_n \quad (19)$$

$$> 0 \quad \text{for } -\epsilon_n < \beta_j < 0 \quad (20)$$

を示せばよい。

(? 最終的に $P(\hat{\beta}_{20} = 0) \rightarrow 1$ が示されたとあるが、これが成り立つことを示すと、 ϵ_n の定義より、 $n \rightarrow \infty$ で ϵ_n は 0 になり、 $0 < \beta_j < 0$ となって、 $\beta_j = 0$ が証明できるということだろうか？だとすると、 $n \rightarrow \infty$ で $\beta_j = 0$ と、 $P(\hat{\beta}_{20} = 0) \rightarrow 1$ の違いはなんだ？)

$$\frac{\partial Q(\beta)}{\partial \beta_j} = \frac{\partial L(\beta)}{\partial \beta_j} - np'_{\lambda_n}(|\beta_j|)\text{sgn}(\beta_j) \quad (21)$$

第 1 項目を β_0 の周りでテイラー展開して、

$$\begin{aligned} \frac{\partial Q(\beta)}{\partial \beta_j} &= \frac{\partial L(\beta)}{\partial \beta_j} - np'_{\lambda_n}(|\beta_j|)\text{sgn}(\beta_j) \\ &= \frac{\partial L(\beta_0)}{\partial \beta_j} + \sum_{l=1}^d \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\beta_l - \beta_{l0}) + \sum_{l=1}^d \sum_{k=1}^d \frac{\partial^3}{\partial \beta_j \partial \beta_l \partial \beta_k} (\beta_l - \beta_{l0})(\beta_k - \beta_{k0}) - np'_{\lambda_n}(|\beta_j|)\text{sgn}(\beta_j) \end{aligned}$$

これを $n\lambda_n$ でくくると、

$$\begin{aligned} \frac{\partial Q(\beta)}{\partial \beta_j} &= n\lambda_n \left[\lambda_n^{-1} n^{-1} \frac{\partial L(\beta_0)}{\partial \beta_j} \right. \\ &\quad + \lambda_n^{-1} n^{-1} \sum_{l=1}^d \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\beta_l - \beta_{l0}) \\ &\quad + \lambda_n^{-1} n^{-1} \sum_{l=1}^d \sum_{k=1}^d \frac{\partial^3}{\partial \beta_j \partial \beta_l \partial \beta_k} (\beta_l - \beta_{l0})(\beta_k - \beta_{k0}) \\ &\quad \left. - \lambda_n^{-1} p'_{\lambda_n}(|\beta_j|)\text{sgn}(\beta_j) \right] \end{aligned}$$

標準的な議論より、

$$n^{-1} \frac{\partial L(\beta_0)}{\partial \beta_j} = O_p(n^{-\frac{1}{2}}) \quad (22)$$

また、

$$\frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} = E \left\{ \frac{L(\beta_0)}{\partial \beta_j \partial \beta_l} \right\} + o_p(1) \quad (23)$$

より

$$\frac{\partial L(\beta_0)}{\partial \beta_j} = n \lambda_n \left\{ -\lambda_n^{-1} p'_{\lambda_n}(|\beta_j|) \text{sgn}(\beta_j) + O_p(n^{-\frac{1}{2}}/\lambda_n) \right\} \quad (24)$$

ここで、仮定より $\liminf_{n \rightarrow \infty} \liminf_{\theta \rightarrow 0+} p'_{\lambda_n}(\theta)/\lambda_n > 0$ なので、1 階微分の符号は β_j によって決定される。

3.5 漸近正規性

局所解は β_1 の関数としてみることで、以下を満たす。

$$\frac{\partial Q(\beta)}{\partial \beta_j} \Big|_{\beta = \begin{pmatrix} \beta_1 \\ 0 \end{pmatrix}} = 0 \quad \text{for } j = 1, \dots, s \quad (25)$$

$$\frac{\partial Q(\beta)}{\partial \beta_j} \Big|_{\beta = \begin{pmatrix} \beta_1 \\ 0 \end{pmatrix}} = \frac{\partial L(\beta)}{\partial \beta_j} \Big|_{\beta = \begin{pmatrix} \beta_1 \\ 0 \end{pmatrix}} - n p'_{\lambda_n}(|\hat{\beta}_j|) \text{sgn}(\hat{\beta}_j) \quad (26)$$

$$= \frac{\partial L(\beta_0)}{\partial \beta_j} + \sum_{l=1}^s \left\{ \frac{\partial^2 L(\beta_0^2)}{\partial \beta_j \partial \beta_l} + o_p(1) \right\} (\hat{\beta}_l - \beta_{l0}) - n \left(p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) + \{p''_{\lambda_n}(|\beta_{j0}|) + o_p(1)\} (\hat{\beta}_j - \beta_{j0}) \right) \quad (27)$$

これは Slutsky's Theorem と中心極限定理に従い、

$$\sqrt{n}(I_1(\beta_{10}) + \Sigma) \{ \hat{\beta}_{10} - \beta_{10} + (I_1(\beta_{10}) + \Sigma)^{-1} \mathbf{b} \} \rightarrow N\{\mathbf{0}, I_1(\beta_{10})\} \quad (28)$$

となる。

(27) を 0 と置いたものの、 $o_p(1)$ の項を無視する。

$$\begin{aligned}
\frac{\partial L(\beta_0)}{\partial \beta_j} + \sum_{l=1}^s \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) - np'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) - np''_{\lambda_n}(|\beta_{j0}|)(\hat{\beta}_j - \beta_{j0}) &= 0 \\
\frac{\partial L(\beta_0)}{\partial \beta_j} &= - \sum_{l=1}^s \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) + np'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) + np''_{\lambda_n}(|\beta_{j0}|)(\hat{\beta}_j - \beta_{j0}) \\
\frac{\partial L(\beta_0)}{\partial \beta_j} &= n \left\{ -\frac{1}{n} \sum_{l=1}^s \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) + p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) + p''_{\lambda_n}(|\beta_{j0}|)(\hat{\beta}_j - \beta_{j0}) \right\} \\
\frac{1}{n} \frac{\partial L(\beta_0)}{\partial \beta_j} &= -\frac{1}{n} \sum_{l=1}^s \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) + p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) + p''_{\lambda_n}(|\beta_{j0}|)(\hat{\beta}_j - \beta_{j0}) \\
\frac{1}{n} \frac{\partial L(\beta_0)}{\partial \beta_j} &= -\frac{1}{n} \sum_{l \neq j} \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2} (\hat{\beta}_j - \beta_{j0}) + p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) + p''_{\lambda_n}(|\beta_{j0}|)(\hat{\beta}_j - \beta_{j0}) \\
\frac{1}{n} \frac{\partial L(\beta_0)}{\partial \beta_j} &= \left\{ p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2} \right\} (\hat{\beta}_j - \beta_{j0}) - \frac{1}{n} \sum_{l \neq j} \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0}) + p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0}) \\
\frac{1}{n} \frac{\partial L(\beta_0)}{\partial \beta_j} &= \left\{ p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2} \right\} \left\{ (\hat{\beta}_j - \beta_{j0}) + \frac{p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0})}{p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2}} - \frac{\frac{1}{n} \sum_{l \neq j} \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0})}{p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2}} \right\}
\end{aligned}$$

右辺の最後の項、

$$-\frac{1}{n} \sum_{l \neq j} \frac{\partial^2 L(\beta_0)}{\partial \beta_j \partial \beta_l} (\hat{\beta}_l - \beta_{l0})$$

については、 $\hat{\beta}_l - \beta_{l0}$ が $n^{\frac{1}{2}}$ のオーダーで 0 にいき、 $\sum_{l \neq j}$ は $s-1$ に関する有限和であるため、この項は $n \rightarrow \infty$ で 0 になる。すると

$$\frac{1}{n} \frac{\partial L(\beta_0)}{\partial \beta_j} = \left\{ p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2} \right\} \left\{ (\hat{\beta}_j - \beta_{j0}) + \frac{p'_{\lambda_n}(|\beta_{j0}|) \text{sgn}(\beta_{j0})}{p''_{\lambda_n}(|\beta_{j0}|) - \frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2}} \right\}$$

となる。これの左辺が中心極限定理より $n \rightarrow \infty$ で正規分布に従うため、右辺も正規分布に従う。

$$\Sigma = \text{diag}\{p''_{\lambda_n}(|\beta_{10}|), \dots, p''_{\lambda_n}(|\beta_{s0}|)\} \quad (29)$$

$$\mathbf{b} = \left(p'_{\lambda_n}(|\beta_{10}|) \text{sgn}(\beta_{10}), \dots, p'_{\lambda_n}(|\beta_{s0}|) \text{sgn}(\beta_{s0}) \right) \quad (30)$$

$$I(\beta_1) = -\frac{1}{n} \frac{\partial^2 L(\beta_0)}{\partial \beta_j^2} \quad (31)$$

とおくと、(28) となる。